

Ejercicio 1

Tenemos que construir un nuevo endpoint en nuestra API que participará en un flujo crítico para pagos con la app de **MercadoPago** vía **QR en locales**, informando al microservicio encargado de cobrar, el porcentaje de descuento que debe aplicar al monto total.

Dado que participamos de un flujo crítico, la app que nos llama nos pide que podamos responderles en menos de 500 ms, incluídos sus reintentos, y podamos mantener un Error Rate < 0.5 % para no afectar a la experiencia del comprador en el comercio.

Para resolver esto, debemos consultar a una api llamada **discounts-api** que nos informa todos los descuentos que aplican al cliente que está pagando, y entregar el más conveniente para él.

Dicha api tiene el siguiente SLA de respuesta

Response Time
Average: 40 ms
P95: 150 ms
P99: 300 ms
MAX: 400 ms
Error Rate: 0.9 %

Arma una propuesta para los valores de configuración del restclient y fundamenta el por qué cada valor:

Timeout
Retries
Cantidad
Strategy

Aclaraciones importantes:

Se puede asumir que no hay requests más “pesados” que otros

Solución

Timeout: 500ms -> 225 ms para cada intento y dejando 50 ms entre ellos.

Tenemos 500ms como máximo. Propongo dividir la ventana de tiempo en dos entre los reintentos y dejar un tiempo entre ambos, para dar lugar a 1 intento original y 1 reintento. Esto significa que, en el peor escenario, se utilizarán 225 ms para el primer intento, 50 ms de espera entre reintentos y 225 ms para el reintento, alcanzando un total de 500 ms.

La API de discounts-api tiene tiempos de respuesta promedio de 40 ms, P95 de 150 ms y, en el peor caso, hasta 400 ms. La mayoría de los casos se resolverán en el primer intento (dentro de los 225 ms) y cuando ocurra un timeout o error transitorio en el primer intento, se podrá realizar un reintento que, en conjunto, no exceda los 500 ms.

Retries: 1 (2 intentos totales)

La discounts-api tiene un error rate de 0.9%; por lo tanto, haciendo un reintento inmediato se reduce la probabilidad de fallo global.

Si suponemos que cada intento falla independientemente con 0.9%, la probabilidad de que ambos fallen es $0.9\% \times 0.9\% \approx 0.0081\%$, lo que ayuda a cumplir el objetivo de un error rate global inferior al 0.5%.

Más de un reintento podría comprometer el límite total de 500 ms, ya que cada intento consume tiempo.

Strategy: Exponential backoff strategy

La estrategia de exponential backoff introduce un retraso entre intentos que permite adaptarse a situaciones de alta carga o errores transitorios.

En nuestro caso, se parte de un retraso base de 50 ms entre los 2 intentos, asegurando que, en caso de error, se dé un pequeño lapso para estabilizar la comunicación sin comprometer el total de 500 ms.