

Ejercicio 2

Suponiendo que nuestro microservicio consume a otro que cuando entre los status code que nos puede devolver se encuentra el **429**, ante el que **reintentamos 2 veces**(*máximo 3 requests, el original más 2 reintentos*), y finalmente devolvemos **500**, porque sin ese valor no podemos proseguir.

Cada vez que el servicio que consumimos devuelve **429** por más de un minuto, nos alertamos porque el tiempo promedio de respuesta sube tendiendo al infinito (60 segundos!) y el error rate sube al 100%. El problema que tenemos es que al reestablecerse el servicio que consumimos, el nuestro no lo hace, manteniendo tiempos altos. hasta que realizamos un black out (cortamos el tráfico entrante y reemplazamos todas las instancias).

Infiera el por qué ocurre esto, y plantee un cambio en la política de reintentos y status code que devuelve nuestro microservicio.

Solución

El problema se debe a que, al recibir un 429 del servicio dependiente, nuestro microservicio realiza 2 reintentos inmediatos (3 requests en total) y, de persistir, devuelve un 500. Esto provoca que se acumulen solicitudes bloqueadas y conexiones ocupadas, generando saturación interna y estados de timeout prolongados. Incluso cuando el servicio dependiente se recupera, nuestras instancias permanecen "atascadas", manteniendo tiempos altos y un error rate del 100% hasta reiniciar (black out).

Para mitigar el problema y lograr que nuestro microservicio se recupere de manera oportuna cuando el servicio dependiente regrese a la normalidad, se podrían realizar los siguientes ajustes:

- Emplear **exponential backoff** en lugar de reintentos inmediatos fijos. Por ejemplo, tras un 429, esperar 50 ms, luego 100 ms antes del siguiente intento, ajustando el delay según el número de reintentos y el tiempo global permitido.
- Evaluar **reducir el número total de reintentos o dejar de reintentar** si se sigue recibiendo 429, evitando sobrecargar el sistema.
- En lugar de devolver siempre un 500 si se agotan los reintentos, responder con un 429 o 503 para **reflejar apropiadamente la saturación** causada por la dependencia. Esto informa al cliente sobre la naturaleza del problema y evita que se interprete como un fallo interno inesperado.